

Daniel Pereira Cinalli

**Estudo de métodos de ensembles com seleção de
classificadores dinâmica**

Projeto de Graduação em Computação sub-
metido à Universidade Federal do ABC para
a obtenção dos créditos na disciplina Projeto
de Graduação em Computação I do curso de
Ciência da Computação

Orientador: Prof. Dr. Thiago Ferreira Covões

Universidade Federal do ABC

17 de Maio de 2021

RESUMO

Ensembles são utilizados pela sua maior capacidade de generalização e também melhor acurácia, quando comparados à utilização de um classificador apenas para a mesma tarefa. Uma abordagem possível é a seleção dinâmica dos classificadores de um ensemble, em que é estimado quais classificadores possuem um melhor desempenho, que então são utilizados para realizar a classificação. Dois métodos de seleção dinâmica serão estudados. O primeiro escolhe os classificadores baseado na acurácia ao classificar objetos conhecidos próximos do objeto que se deseja classificar. O segundo utiliza o conceito de similaridade de decisão, escolhendo uma porcentagem dos classificadores que mais concordam na classificação de uma quantidade escolhida de objetos, gerados aleatoriamente na proximidade do objeto que se quer classificar.

SUMÁRIO

1	Introdução	1
2	Justificativa	4
3	Fundamentação teórica	5
3.1	Validação cruzada	5
3.2	Ensembles	5
3.3	Bagging	6
3.4	Rank médio	6
3.5	Diagrama de diferença crítica	6
3.6	Árvore de decisão	7
3.7	Perceptron	8
3.8	Classificador Naïve Bayes	8
3.9	Classificador kNN	9
4	Metodologia	10
4.1	Método de seleção por acurácia	10
4.2	Método de seleção por similaridade	11
4.3	Experimentos e análise	11
5	Cronograma	13
6	Resultados	14
7	Conclusão	21

R	Referências	22
A	Boxplots dos resultados	24

INTRODUÇÃO

Em aprendizado de máquina, modelos preditivos são gerados à partir de um conjunto de dados, para que se possa fazer previsões. Um modelo pode ser um classificador, caso se deseje realizar uma previsão categórica, ou um regressor, quando o que se quer é uma previsão numérica [Zhou 2012]. O foco deste estudo será em classificação, que de acordo com [Tan, Steinback e Kumar 2006], é a tarefa de se aprender uma função f que mapeia cada conjunto de atributos x para uma das classes predefinidas y .

O desempenho de generalização de um classificador é definido como seu desempenho em classificar objetos não utilizados durante a fase de treinamento. Uma motivação do uso de *ensembles* é sua maior capacidade de generalização, se comparado à utilização de um único classificador para a mesma tarefa. Para obter isto é feita a combinação das previsões dos diversos classificadores do *ensemble*, o que reduz o efeito daqueles classificadores que apresentam um desempenho insatisfatório [Polikar 2006].

Entre os métodos de combinação para previsões numéricas, pode-se citar os métodos de média simples e média ponderada. Para previsões nominais, alguns métodos são voto da maioria, em que é necessário que pelo menos um dos resultados possíveis tenha recebido mais de metade dos votos; voto plural, onde simplesmente é escolhido aquele com mais

votos; votação ponderada, entre outros. Existem, no entanto, diversos outros modos de se combinar os resultados de um *ensemble* [Zhou 2012].

Dado que um *ensemble* considera a predição de diversos classificadores, é desejável que este conjunto de classificadores possua alta diversidade. Caso os classificadores individuais sejam similares, não haverá um ganho grande ao se combinar seus resultados. Ou seja, os classificadores individuais que fazem parte do *ensemble* devem ter uma baixa correlação entre si. Classificadores com alta correlação entre si em geral diminuem o erro do *ensemble* menos se comparado a um *ensemble* onde estes possuem baixa correlação entre si, e se reduz ainda mais no caso de uma correlação negativa [Kuncheva e Whitaker 2003].

Uma alta diversidade portanto deve levar a uma melhor acurácia do *ensemble*, mas mensurar esta diversidade é difícil, e diversos métodos existentes não chegam a uma medida de diversidade que apresente boa correlação com a acurácia do *ensemble*. É entendido que esses métodos não sejam bons indicadores de diversidade, mas que a busca por diversidade ainda é importante [Zhou 2012].

Em classificação, existem também técnicas de seleção dinâmica de classificadores. Em seleção dinâmica, é feita uma estimativa daqueles classificadores com melhor desempenho, que então são utilizados para realizar a classificação [Cruz, Sabourin e Cavalcanti 2018]. Neste trabalho, será estudado o desempenho de dois métodos onde os classificadores de um *ensemble* são escolhidos dinamicamente, que serão introduzidos a seguir.

O primeiro método escolhe os melhores classificadores de acordo com a acurácia local, com base nos objetos de seu conjunto de treinamento e validação. Para isso, se escolhe os objetos mais próximos do objeto que se deseja classificar, e se determina a acurácia com base nestes. Com base nesses resultados, se determina quais classificadores serão utilizados para fazer a classificação.

O segundo método será baseado no artigo [Kurvers et al. 2019], onde foi analisada a ideia de se utilizar a similaridade de decisão para se encontrar indivíduos ou grupos com alto desempenho. Neste, a similaridade de decisão entre diferentes indivíduos foi usada para prever a acurácia destes. Em [Cruz, Sabourin e Cavalcanti 2018], é proposto que enquanto é necessário ter diversidade entre os classificadores disponíveis em todo o *ensemble*,

se deve ter consenso, e não diversidade, entre os classificadores selecionados para a tarefa de predição.

A similaridade de decisão é medida apresentando um conjunto de perguntas que cada indivíduo deve responder. Para cada indivíduo, se calcula a porcentagem de concordância em relação a cada outro indivíduo, ou seja, o quanto concordam nas respostas às perguntas. A similaridade de decisão de cada indivíduo será a média das porcentagens de concordância calculadas para este. Tanto na análise matemática quanto na empírica, se concluiu que a abordagem é viável, encontrando grupos com melhor desempenho [Kurvers et al. 2019].

Diferentemente do método anterior, que busca objetos próximos já existentes, os objetos serão gerados aleatoriamente, próximos ao objeto que se quer classificar, e a decisão de quais serão os classificadores escolhidos será baseado na similaridade de decisão.

Embora estes métodos estejam escolhendo apenas alguns classificadores para realizar a predição, o objetivo é identificar bons classificadores localmente, e ainda é importante que o *ensemble* como um todo possua alta diversidade.

JUSTIFICATIVA

O presente trabalho busca explorar duas técnicas em que se realiza a seleção dinâmica de classificadores em um ensemble. Essa técnica de seleção dinâmica tem como objetivo aumentar a acurácia de uma predição, selecionando por algum critério quais classificadores do ensemble serão utilizados para a predição sendo realizada para um dado objeto. Deseja-se determinar se as técnicas estudadas são viáveis como uma ferramenta para se obter uma melhor acurácia para um ensemble.

A técnica que utiliza o critério de similaridade de decisão foi baseada em [Kurvers et al. 2019]. No artigo se mostra que este critério consegue obter uma maior acurácia selecionando um subconjunto de todos os indivíduos de um grupo para se fazer uma predição, se comparado a utilizar o conhecimento combinado de todos. Dado o resultado positivo apresentado no artigo, a técnica será implementada em um ensemble para determinar seu desempenho no contexto de aprendizado de máquina.

FUNDAMENTAÇÃO TEÓRICA

Neste capítulo são apresentados os fundamentos de *ensembles* e validação cruzada, assim como os classificadores que serão utilizados como base para os *ensembles*.

3.1 Validação cruzada

Em validação cruzada, um conjunto de dados é particionado em k partes de mesmo tamanho. Uma dessas partições será o conjunto de teste enquanto as outras $k - 1$ partes serão usadas para treinamento. Isso é repetido até todas as k partições terem sido utilizadas como conjunto de teste [Tan, Steinback e Kumar 2006].

3.2 Ensembles

Ensembles consistem de um conjunto de classificadores base treinados no conjunto de treinamento. A classificação realizada pelo *ensemble* é realizada por votação das predições feitas pelos classificadores base. Esse método tem como objetivo aumentar a acurácia de classificação, se comparado ao utilizar um de seus classificadores base apenas. Para se conseguir isso, há duas condições necessárias:

- Os classificadores base devem ser independentes entre si;
- Os classificadores base devem ter desempenho melhor que uma escolha aleatória.

Na primeira condição, dois classificadores serem independentes significa que seus erros não são correlacionados entre si. Na segunda condição, se implica que cada classificador precisa ter uma taxa de erros menor que 50% [Tan, Steinback e Kumar 2006].

3.3 Bagging

O termo *bagging* se refere a *bootstrap aggregating*. Dado um *dataset* com m exemplos de treinamento, se toma deste uma amostra de m exemplos usando amostragem com substituição. Com essa abordagem, não se diminui a quantidade de exemplos que cada classificador do *ensemble* usará para ser treinado, evitando treinamento sobre amostras pouco representativas [Zhou 2012].

3.4 Rank médio

Para cada par de algoritmo e *dataset*, se tem a acurácia obtida no experimento. Para um *dataset*, um *rank* é dado para cada algoritmo, sendo *rank* 1 para a maior acurácia, *rank* 2 para a segunda maior, e assim por diante. Em caso de um empate, um *rank* médio é atribuído. Por exemplo, caso os 2 melhores algoritmos empatem, seus *ranks* serão 1,5, a média entre 1 e 2. Ao final, se obtém o *rank* médio para um algoritmo pela média de seus *ranks* sobre todos os *datasets*

3.5 Diagrama de diferença crítica

O diagrama de diferença crítica representa os resultados do teste de Nemenyi. Neste teste, dois classificadores tem um desempenho significativamente diferente caso seus *ranks* tenham entre si uma diferença maior que a diferença crítica CD , dada pela equação

$$CD = q_\alpha \sqrt{\frac{k(k+1)}{6N}} \quad (3.1)$$

em que q_α é dado pela tabela de amplitude estudentizada dividida por $\sqrt{2}$. N se refere à quantidade de *datasets* e k à quantidade de algoritmos.

No diagrama, se mostra todos os *ranks* médios dos algoritmos, com barras juntando os algoritmos sem diferença significativa. Uma barra no topo representa o valor da diferença crítica CD [Demšar 2006].

3.6 Árvore de decisão

Uma árvore de decisão é composta de nós de decisão e de nós folha. Em cada nó de decisão, é implementada uma função de teste com saídas discretas, em que o resultado do teste determina qual o próximo nó escolhido. Isso ocorre até se encontrar um nó folha, que é um nó em que se encontra uma das possíveis saídas. Para se gerar uma árvore de decisão para classificação, se quantiza o quão boa é uma divisão criada por um nó de decisão usando uma medida de impureza. Uma medida possível é a função de entropia, que para um nó m e exemplo i é dada por [Alpaydin 2010]:

$$I_m = - \sum p_m^i \log_2 p_m^i \quad (3.2)$$

Uma divisão pura, por exemplo, é uma em que a distribuição das classes após a divisão será (0, 1). A construção da árvore é feita se escolhendo a decisão com entropia mínima. Isso é feito recursivamente até que todas as divisões sejam puras. O tamanho do espaço de busca faz com que seja inviável de se encontrar uma árvore ótima, e por isso algoritmos de construção de árvores de decisão usualmente utilizam uma estratégia gulosa que faz decisões localmente ótimas [Tan, Steinback e Kumar 2006].

3.7 Perceptron

Um perceptron possui n entradas e 1 saída. Para cada entrada x_j , está associado um peso w_j , e também um termo de *bias* w_0 . O caso mais simples para se calcular a saída é a média ponderada, apresentada abaixo:

$$y = \sum_{j=1}^n w_j x_j + w_0 \quad (3.3)$$

O termo w_0 pode ser visto como se fosse associado a um termo x_0 , com valor sempre igual a 1. A saída do perceptron pode então ser representada pelo produto escalar abaixo:

$$y = \mathbf{w}^T \mathbf{x} \quad (3.4)$$

em que $\mathbf{x} = [1, x_1, \dots, x_n]$ e $\mathbf{w} = [1, w_1, \dots, w_n]$. Durante o treinamento, se aprendem os pesos \mathbf{w} . Em treinamento online inicia-se com pesos aleatórios, a saída y é calculada para a primeira instância da entrada, os pesos são atualizados e o processo é repetido até que toda instância tenha passado pelo perceptron. Abaixo é mostrado o valor da atualização dos pesos, onde α é a taxa de aprendizado, $y^{(t)'}$ é a predição, $y^{(t)}$ é o valor real, e $x_j^{(t)}$ é a entrada, para a instância t :

$$\Delta w_j^{(t)} = \alpha (y^{(t)} - y^{(t)'}) x_j^{(t)} \quad (3.5)$$

3.8 Classificador Naïve Bayes

O teorema de Bayes é utilizado para se determinar a probabilidade de um evento Y ocorrer dado que se conhece que o evento X já ocorreu, e é dado pela seguinte equação:

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)} \quad (3.6)$$

Para se utilizar o teorema de Bayes para classificação, é necessário aprender as probabilidades a posteriori $P(Y|\mathbf{X})$, em que Y é a classe e \mathbf{X} é o conjunto de atributos, à partir dos dados de treinamento. Sabendo essas probabilidades e sendo \mathbf{X}' o objeto que quer se classificar, se

encontra a classe Y' que maximiza a probabilidade a posteriori $P(Y'|\mathbf{X})$. O teorema de Bayes é utilizado então para se expressar esta probabilidade em função de $P(Y)$ (probabilidade a priori), $P(\mathbf{X}|Y)$ (probabilidade condicional de classe), e $P(\mathbf{X})$ (evidência) [Tan, Steinback e Kumar 2006].

Em uma classificador Naïve Bayes, se supõe que os atributos são condicionalmente independentes. Com essa suposição se tem a seguinte relação:

$$P(\mathbf{X}|Y = y) = \prod_{i=1}^n P(X_i|Y = y) \quad (3.7)$$

Com essa suposição, não é necessário computar a probabilidade condicional de classe para cada combinação de \mathbf{X} , apenas computando a probabilidade condicional para cada X_i , dado um Y . Com isso, para se classificar um objeto, se usa a seguinte equação para se obter a probabilidade a posteriori de cada classe:

$$P(Y|\mathbf{X}) = \frac{P(Y) \prod_{i=1}^n P(X_i|Y)}{P(\mathbf{X})} \quad (3.8)$$

É suficiente se maximizar o numerador para se encontrar a classe do objeto, já que $P(\mathbf{X})$ será igual para todo Y .

3.9 Classificador kNN

O classificador kNN (*k-nearest neighbours*) computa a distância entre o objeto \mathbf{X} que se deseja classificar e cada exemplo do conjunto de treinamento, e então seleciona os k mais próximos dentre estes, gerando o conjunto denotado por $D_{\mathbf{X}}$. O processo para se escolher a classe consiste então de uma votação majoritária, onde a classe em maior número em $D_{\mathbf{X}}$ é a predição para o objeto \mathbf{X} [Tan, Steinback e Kumar 2006].

METODOLOGIA

Neste capítulo serão apresentados em maior detalhe como os métodos estudados funcionam. Ao final se apresentam como os experimentos serão realizados e como será feita a análise dos resultados

4.1 Método de seleção por acurácia

O primeiro método escolhe os melhores classificadores de acordo com a acurácia local, com base nos objetos de seu conjunto de treinamento e validação. Possui dois parâmetros: N , o número de objetos próximos que serão considerados; e Acc_{\min} , a acurácia mínima necessária para se aceitar um classificador. O processo para se classificar um objeto P é descrito abaixo:

1. Escolhe-se os N objetos mais próximos do objeto que se quer classificar;
2. Calcula-se a acurácia de cada classificador com base nesses objetos;
3. Se determina quais classificadores serão utilizados na classificação, filtrando aqueles com acurácia menor que Acc_{\min} . No caso de nenhum classificador possuir acurácia maior que a mínima, o com maior acurácia será escolhido;

4. Pesos são dados a cada classificador, proporcionais à sua acurácia;
5. É feita uma média ponderada das classificações de cada classificador escolhido, e o resultado é normalizado.

4.2 Método de seleção por similaridade

Como explicado anteriormente, neste método os objetos serão gerados aleatoriamente, próximos ao objeto que se quer classificar, e a decisão de quais serão os classificadores escolhidos será baseado na similaridade de decisão. Os parâmetros para este método são: N , a quantidade de objetos aleatórios que serão gerados; M , a quantidade de classificadores que serão escolhidos. O processo para se classificar um objeto P é o seguinte:

1. São gerados N objetos próximos a P ;
2. Cada classificador então classifica estes objetos;
3. Cada classificador tem sua similaridade de decisão calculada;
4. Os M classificadores com maior similaridade de decisão são escolhidos;
5. O objeto P é classificado considerando apenas estes classificadores.

O processo para se gerar objetos próximos a P é explicado a seguir. Se sabe o desvio padrão original σ_i para cada atributo i , obtidos do conjunto de treinamento. Para se gerar um dos objetos aleatórios próximo a P , cada atributo i seguirá uma distribuição normal, com média igual ao valor para aquele atributo em P , e com desvio padrão igual a 10% de σ_i .

4.3 Experimentos e análise

Os experimentos serão realizados sobre 10 *datasets*, utilizando 20 classificadores-base em cada *ensemble*, variando-se o parâmetro relevante de cada método. Em cada experimento é utilizado 5 *folds* para validação cruzada. São utilizados 4 tipos de classificadores-base: Árvores de decisão, perceptrons, Naïve Bayes, e kNN. Além desses, foi também utilizado um

ensemble misto composto de classificadores de árvores de decisão, perceptrons e kNN, para se estudar a performance do método com um *ensemble* misto. Para se obter classificadores-base que não sejam idênticos, se utilizou *bagging*.

Para o método de seleção por acurácia, se varia a acurácia mínima necessária de 0% a 100%, em passos de 5%, em que 0% é equivalente a se utilizar a *ensemble* completa. Para o método de seleção por similaridade, se varia a porcentagem de classificadores que serão escolhidos de 5% a 100%, em passos de 5%, em que 100% é equivalente a se utilizar o *ensemble* completo.

Para análise será utilizado o *rank* médio. Também será utilizado o diagrama de diferença crítica na análise, para se determinar a significância dos resultados. Os dois métodos estudados serão analisados separadamente.

CRONOGRAMA

Neste capítulo é apresentado o cronograma das atividades, na Tabela 5.1 abaixo.

(A) - **Levantamento Bibliográfico** - Pesquisa e leitura do material necessário para a fundamentação teórica;

(B) - **Implementação** - Desenvolvimento dos dois métodos;

(C) - **Aplicação** - Aplicação dos métodos em conjuntos de dados;

(D) - **Análise de Resultados** - Analisar os resultados obtidos em relação com o esperado do projeto, e discussão de propostas futuras;

(E) - **Escrita do Relatório Técnico** - Escrita do texto;

(F) - **Elaboração da apresentação** - Apresentação que será feita ao final do projeto.

Tabela 5.1: Cronograma

Atividades	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
A	X	X	X	X	X	X	X				
B			X	X	X	X	X				
C					X	X	X	X			
D								X	X	X	X
E	X	X	X	X	X	X	X	X	X	X	X
F										X	X

RESULTADOS

Após se obter os dados, para se facilitar a visualização, os dados foram separados pelo classificador-base. Na Tabela 6.1, cada classificador-base possui os *ranks* ordenados, e o parâmetro se refere à acurácia mínima.

Tabela 6.1: Resultados do método de acurácia

kNN		Mix		Naïve-Bayes		Perceptron		Árvore de decisão	
Rank	Parâmetro	Rank	Parâmetro	Rank	Parâmetro	Rank	Parâmetro	Rank	Parâmetro
44,25	0,35	22,10	0,10	77,70	0,60	60,10	0,55	14,25	0,05
45,40	0,45	22,60	0,65	77,80	0,80	61,10	0,60	15,90	0,10
47,80	0,75	22,65	0,45	79,30	0,70	62,85	0,65	16,30	0,00
48,10	0,55	23,70	0,30	79,90	0,95	63,35	0,50	19,00	0,45
48,85	0,65	24,05	0,25	80,40	0,90	64,15	0,45	19,00	0,40
49,30	0,40	24,70	0,50	80,40	0,65	64,70	0,40	19,30	0,30
49,30	0,25	24,95	0,35	80,60	0,85	65,00	0,75	20,70	0,15
49,55	0,60	25,90	0,60	81,60	0,50	65,85	0,70	21,00	0,35
50,45	0,00	25,95	0,55	81,75	0,75	66,70	0,35	21,80	0,75
51,05	0,85	26,30	0,20	82,00	1,00	67,55	0,30	22,15	0,70
51,70	0,30	27,40	0,40	83,55	0,55	67,65	0,95	22,35	0,65
51,85	0,70	27,45	0,00	85,55	0,45	69,25	0,85	22,75	0,25
52,55	0,10	28,15	0,15	86,00	0,40	71,25	0,20	22,90	0,50
52,70	0,05	28,35	0,70	86,90	0,35	71,60	0,80	23,00	0,20
52,80	0,15	32,60	0,05	87,55	0,30	72,40	0,25	24,20	0,60
53,20	0,50	33,00	0,75	88,90	0,25	72,85	0,00	24,20	0,55
57,05	0,20	33,90	0,80	90,65	0,10	74,40	0,10	30,50	0,85
57,90	0,80	34,95	0,85	91,10	0,20	75,45	0,90	33,90	0,80
60,60	0,95	52,35	0,90	91,30	0,15	77,05	0,05	43,35	0,90
63,30	0,90	53,90	0,95	91,65	0,05	77,20	1,00	44,90	0,95
73,80	1,00	74,40	1,00	94,05	0,00	78,95	0,15	74,65	1,00

Com esses dados se elaborou o gráfico apresentado na Figura 6.1. Pode se observar uma tendência para *ranks* melhores conforme se diminui a acurácia mínima para os *ensembles* compostos de árvore de decisão e o misto. O *ensemble* composto de classificadores kNN apresenta uma pequena tendência positiva, Naïve-Bayes apresenta uma tendência negativa enquanto o perceptron não parece apresentar uma tendência. Nota-se que a escolha do classificador-base de cada *ensemble* apresentou uma influência maior no *rank* do que a escolha do parâmetro de acurácia mínima.




Figura 6.1: Gráfico de dispersão para o método da acurácia

Para se analisar a significância da diferença entre os parâmetros testados, é utilizado o diagrama de diferença crítica. Como há muitos classificadores para se comparar em um diagrama, o melhor e o pior *rank* para cada classificador-base foram selecionados, de acordo com a Tabela 6.1. Na Figura 6.2, pode ser observado que apenas para o classificador-base

árvore de decisão há uma diferença significativa entre seu pior e melhor caso. Para os outros, no entanto, se conclui que variar o parâmetro de acurácia mínima não obteve resultados significativos.




Figura 6.2: Diagrama de diferença crítica para o método da acurácia

Na Tabela 6.2 são apresentados os *ranks* para o método da similaridade. O parâmetro para o método é a quantidade de classificadores escolhidos.

Tabela 6.2: Resultados do método de similaridade

kNN		Mix		Naïve-Bayes		Perceptron		Árvore de decisão	
Rank	Parâmetro	Rank	Parâmetro	Rank	Parâmetro	Rank	Parâmetro	Rank	Parâmetro
35,45	16	14,70	19	69,35	15	76,75	13	12,70	17
35,70	15	16,90	18	71,60	11	76,80	3	13,60	15
37,70	18	18,60	20	71,75	5	77,00	7	14,85	19
38,15	13	19,00	13	72,25	20	77,80	18	16,80	20
39,70	17	20,95	16	72,90	14	78,25	10	17,70	14
40,45	20	21,65	15	73,00	19	78,55	11	17,75	13
40,75	12	22,05	14	73,65	6	78,60	16	19,40	16
40,85	19	22,90	17	73,70	12	78,90	6	19,45	18
40,90	14	23,55	10	74,50	8	79,00	4	20,15	12
43,05	9	24,20	12	74,90	16	79,60	14	22,25	9
44,30	6	26,85	9	75,00	13	79,85	12	22,35	8
44,95	11	26,90	8	75,00	3	80,55	8	23,55	11
45,05	8	27,60	5	75,40	10	81,00	19	26,85	10
46,65	10	27,95	6	75,80	17	81,25	15	27,55	7
47,40	7	28,05	7	76,25	7	82,40	2	34,25	5
48,00	5	28,75	11	78,65	9	82,60	20	34,65	6
48,90	4	35,70	4	78,80	18	82,90	9	35,75	3
50,30	3	37,15	3	79,85	4	83,30	17	39,15	4
54,25	1	44,00	2	81,60	2	83,70	5	53,45	1
55,00	2	48,40	1	83,00	1	84,85	1	53,85	2

A Figura 6.3 apresenta as tendências do *rank* para o método de similaridade. Há uma tendência negativa para os *ensembles* com classificadores-base árvores de decisão, kNN e misto. Os outros *ensembles* não apresentam uma tendência. Novamente se percebe que a escolha de classificador-base apresenta maior influência do que o parâmetro.




Figura 6.3: Gráfico de dispersão para o método da similaridade

Foi feita a mesma análise utilizando-se o diagrama de diferença crítica. Na Figura 6.4, se observa que a variação do parâmetro de classificadores escolhidos não obteve diferenças significantes.




Figura 6.4: Diagrama de diferença crítica para o método da similaridade

As próximas figuras são *boxplots* das acurácias obtidas para algumas das configurações de método estudado e classificador-base. As demais figuras se encontram no apêndice.

Na Figura 6.5, para o *dataset Electrical Grid Stability*, uma região entre 5 e 12 classificadores escolhidos, que apresenta uma maior acurácia se comparada ao se usar todos os classificadores.

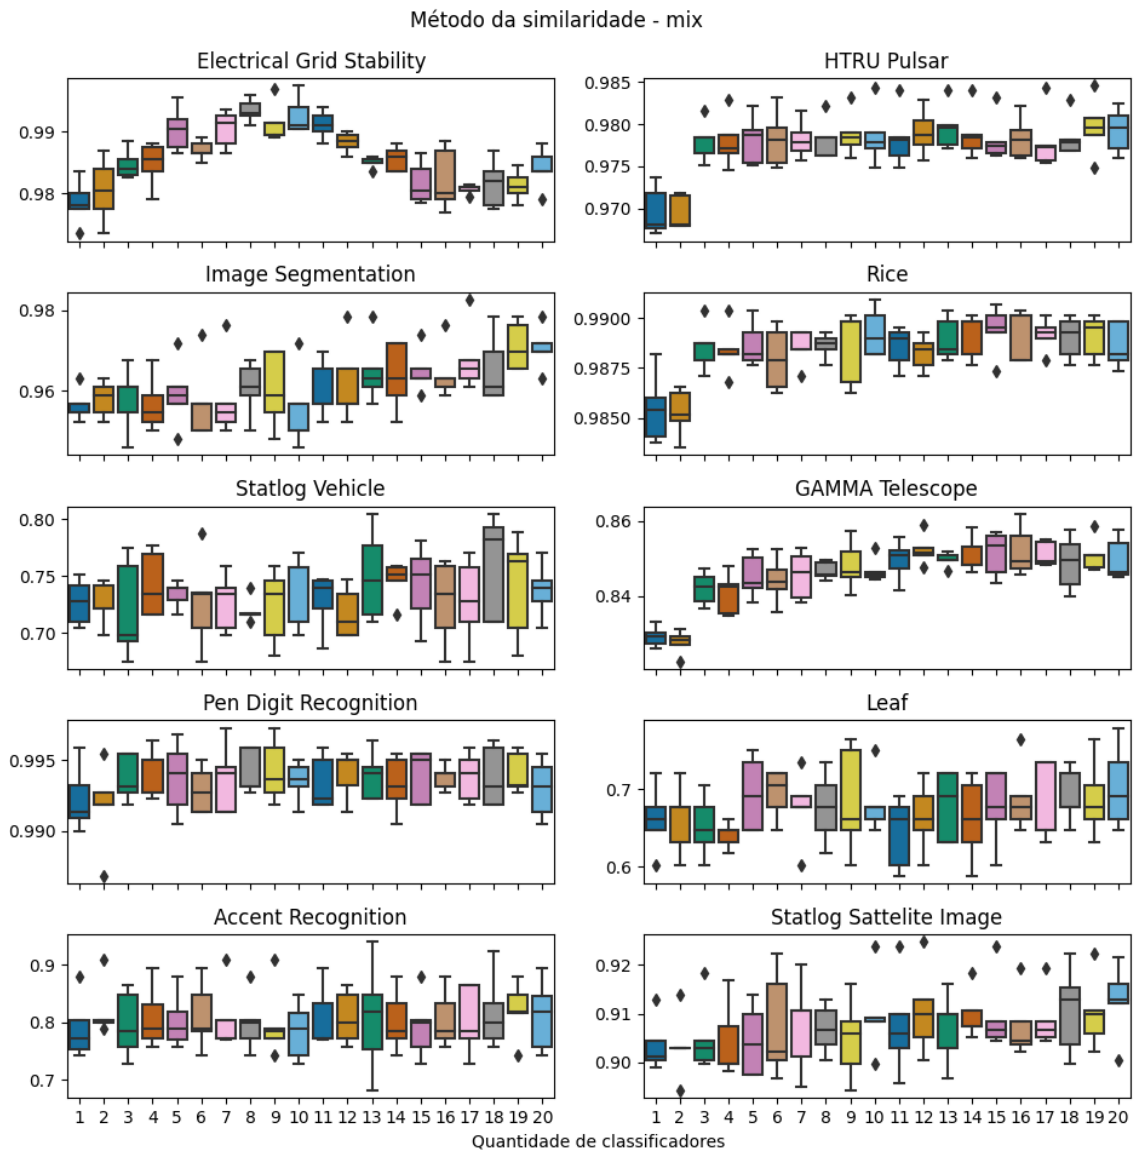


Figura 6.5: Resultados do método de similaridade com classificador-base misto

Na Figura 6.6, pode se observar que ao se selecionar uma acurácia mínima de 100%, há uma queda na acurácia. Isso se deve ao fato que é possível conforme se aumenta a acurácia mínima, de que nenhum classificador-base consiga atingir esse mínimo. Neste caso,

o algoritmo escolhe apenas o melhor classificador, para que seja possível continuar com a predição.

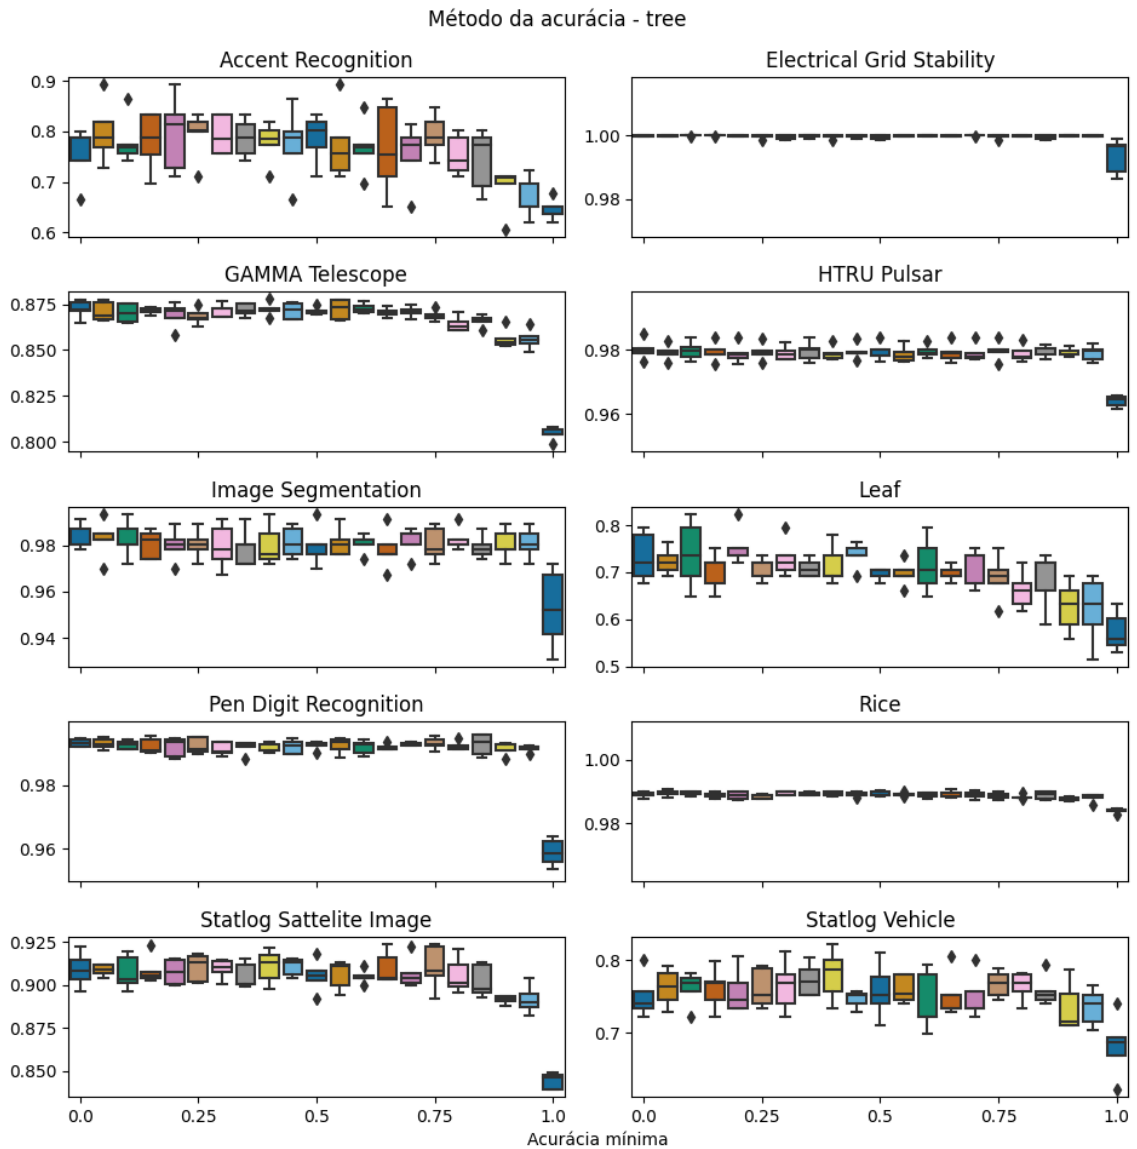


Figura 6.6: Resultados do método de acurácia com classificador-base árvore de decisão

Para o método da similaridade, embora tenha casos em que há a tendência de se aumentar a acurácia conforme se usam mais classificadores, também há casos onde a acurácia não apresenta uma tendência. Isso pode ser visto na Figura 6.7.

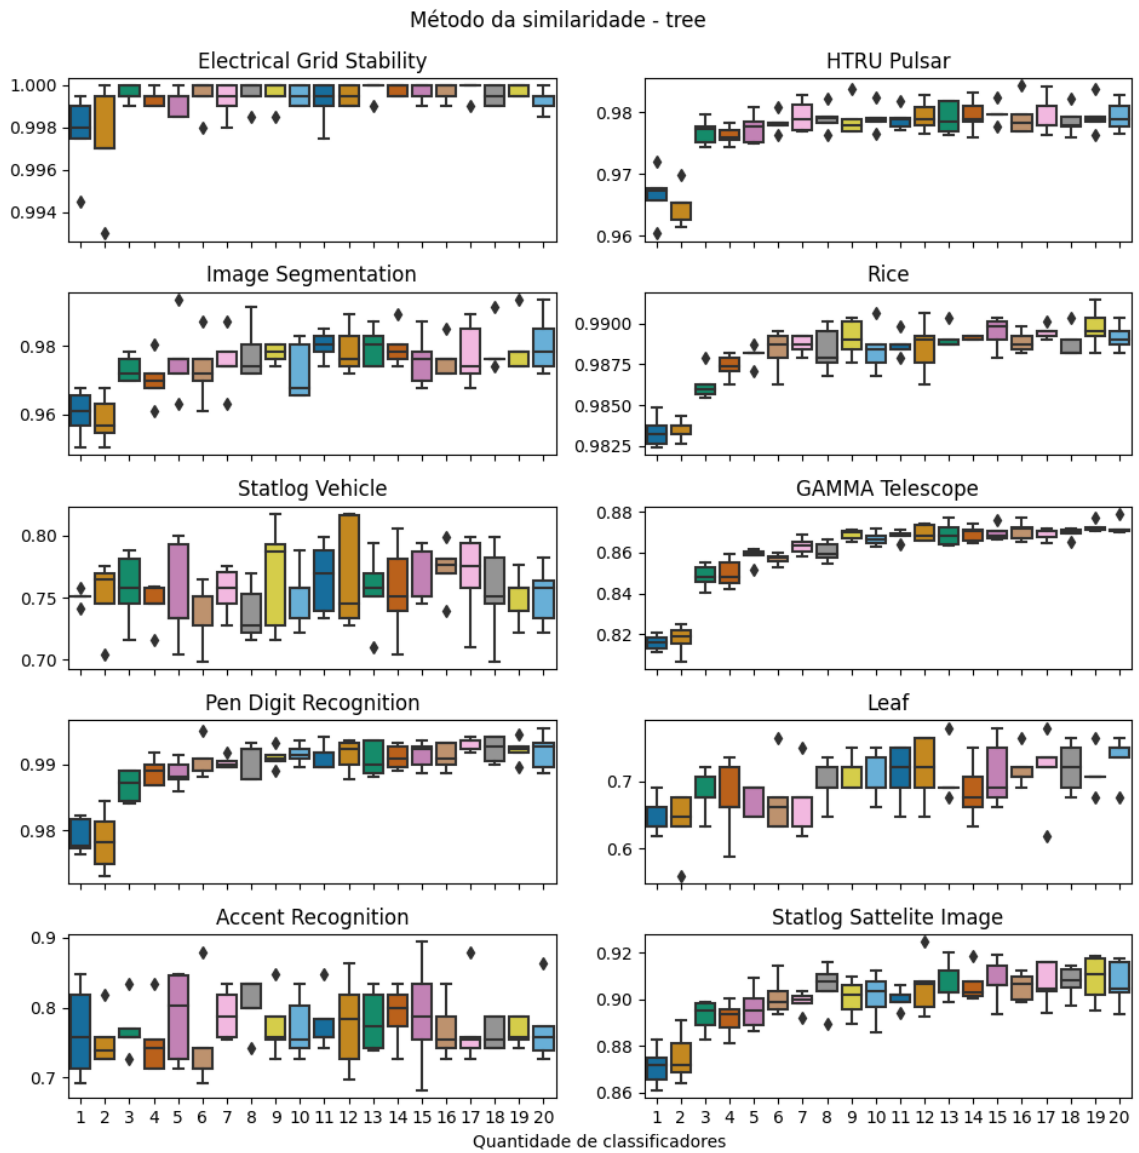


Figura 6.7: Resultados do método de similaridade com classificador-base árvore de decisão

CONCLUSÃO

A proximidade das curvas entre os *ensembles* compostos de árvores de decisão e os mistos podem indicar que para o *ensemble* misto as árvores de decisão tiveram a maior influência.

Com base nos resultados obtidos para o método de seleção por acurácia é possível concluir que dentre os classificadores estudados apenas Naïve-Bayes apresenta uma melhora ao se aumentar a acurácia mínima necessária para seleção. Para os outros classificadores, parece não se ter um ganho em desempenho em se utilizar o método. Apenas para o caso com o classificador-base árvore de decisão se obteve diferenças significativas ao se variar a acurácia mínima.

O método de seleção por similaridade não apresenta melhora ao se escolher uma quantidade menor de classificadores. Os resultados indicam que ao não se utilizar o método se tende a um melhor desempenho, embora a diferença ao se variar a quantidade de classificadores escolhidos não seja significativa.



REFERÊNCIAS

- [Alpaydin 2010]ALPAYDIN, E. *Introduction to Machine Learning*. [S.l.: s.n.], 2010.
- [Cruz, Sabourin e Cavalcanti 2018]CRUZ, R. M. O.; SABOURIN, R.; CAVALCANTI, G. D. C. Dynamic classier selection: Recent advances and perspectives. *Information Fusion*, v. 41, p. 195–216, 2018.
- [Demšar 2006]DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, v. 7, n. 1, p. 1–30, 2006. Disponível em: <<http://jmlr.org/papers/v7/demsar06a.html>>.
- [Kuncheva e Whitaker 2003]KUNCHEVA, L.; WHITAKER, C. Measures of diversity in classifier ensembles and their relationship with the ensemble accuracy. *Machine Learning*, v. 51, p. 181207, 2003.
- [Kurvers et al. 2019]KURVERS, R. H. J. M. et al. How to detect high-performing individuals and groups: Decision similarity predicts accuracy. *Science Advances*, American Association for the Advancement of Science, v. 5, n. 11, 2019. Disponível em: <<https://advances.sciencemag.org/content/5/11/eaaw9011>>.
- [Polikar 2006]Polikar, R. Ensemble based systems in decision making. *IEEE Circuits and Systems Magazine*, v. 6, n. 3, p. 21–45, 2006.

[Tan, Steinback e Kumar 2006] TAN, P.-N.; STEINBACK, M.; KUMAR, V. *Introduction to Data Mining*. [S.l.: s.n.], 2006.

[Zhou 2012] ZHOU, Z.-H. *Ensemble methods: Foundations and algorithms*. [S.l.]: Taylor Francis Group, LLC, 2012.

BOXPLOTS DOS RESULTADOS

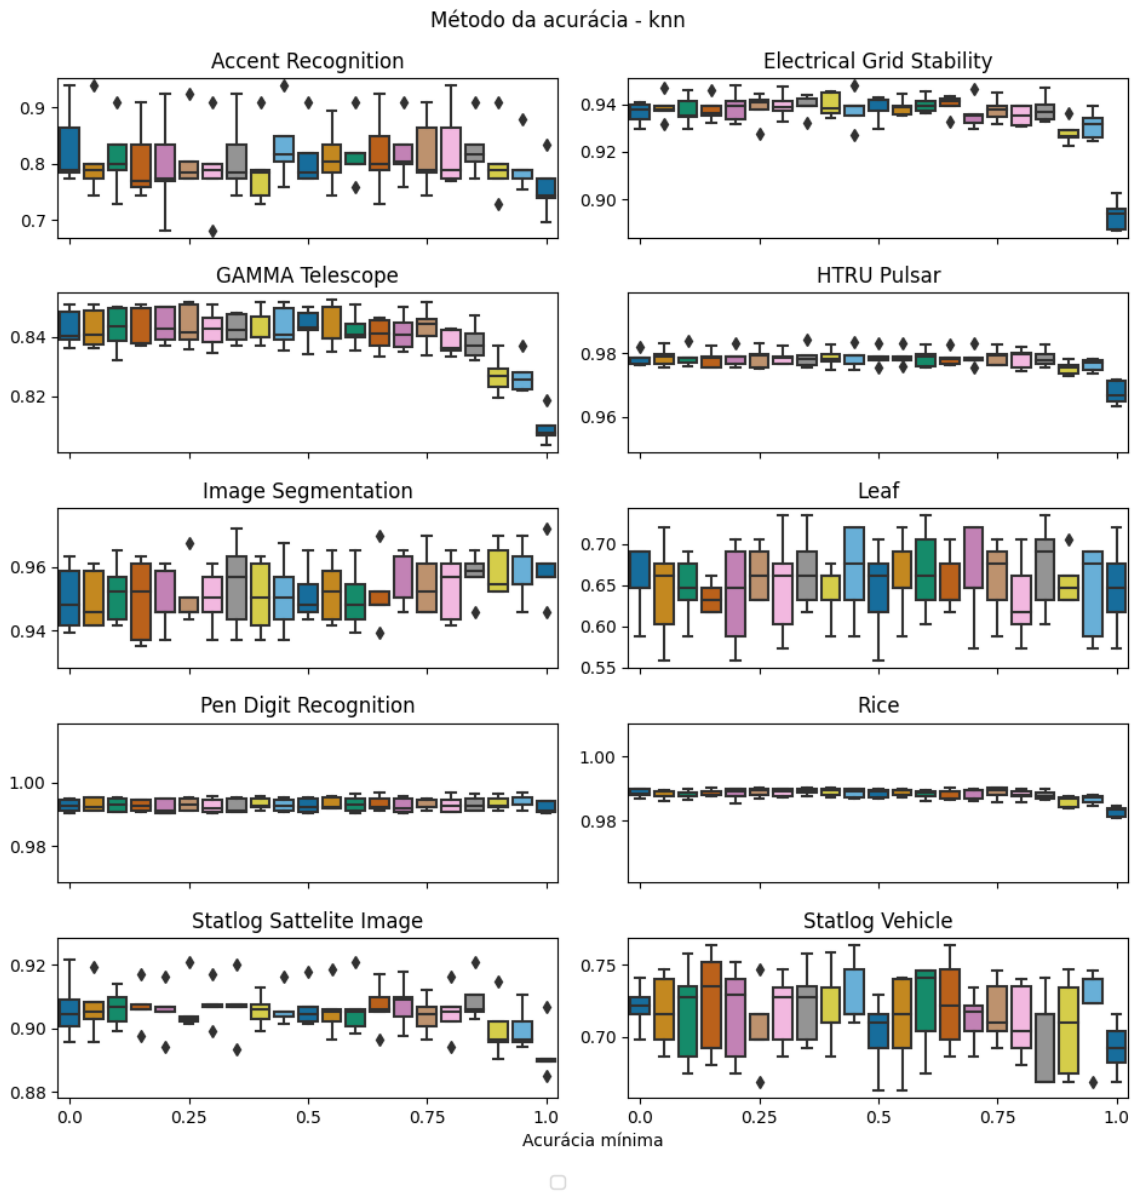


Figura A.1: Resultados do método de acurácia com classificador-base kNN

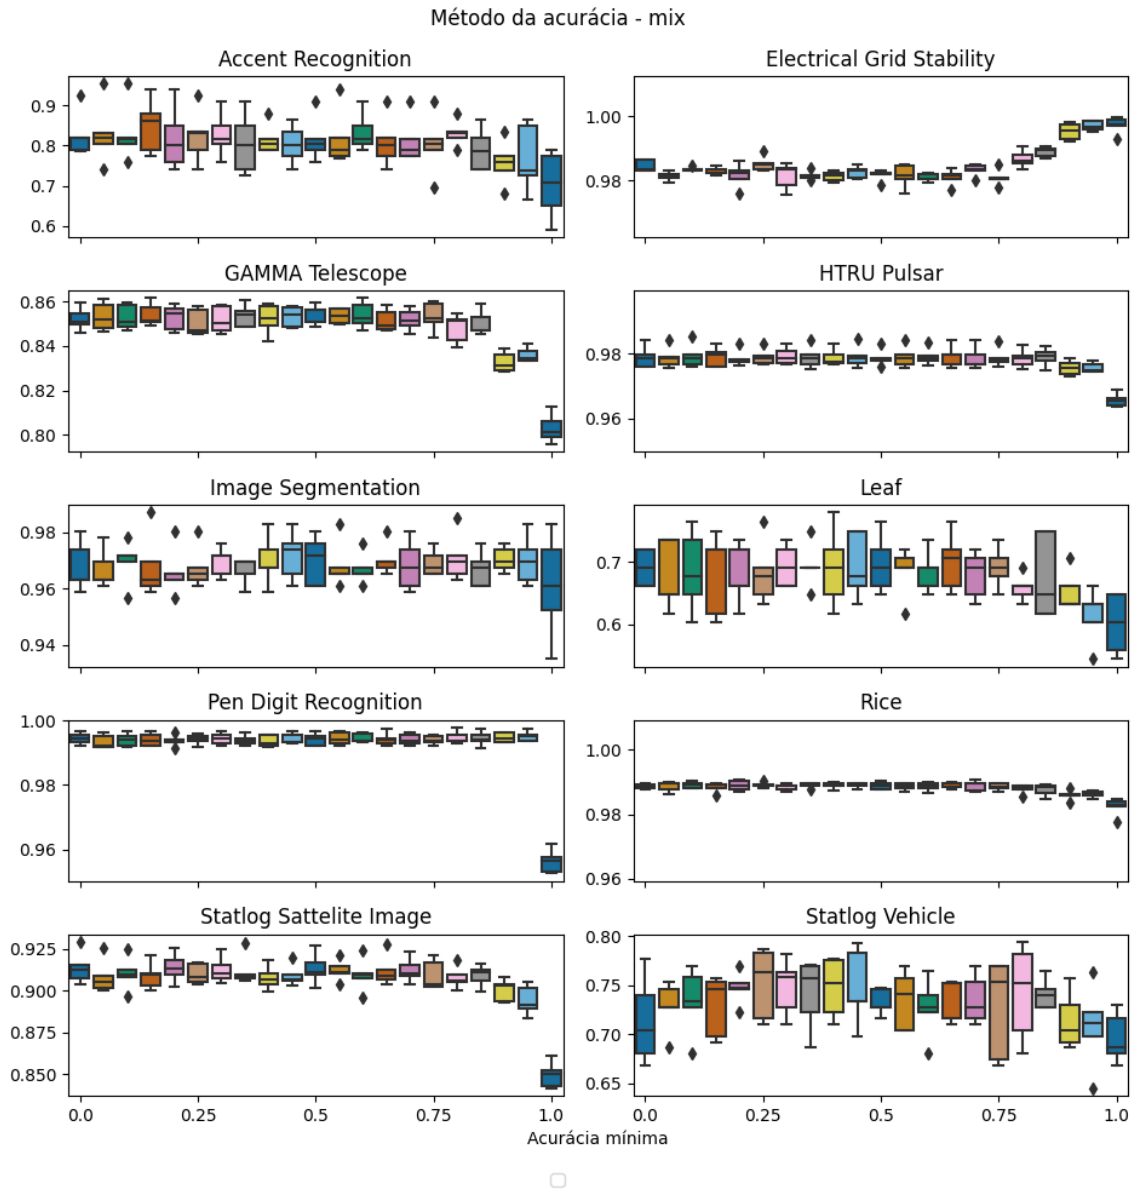


Figura A.2: Resultados do método de acurácia com classificador-base misto

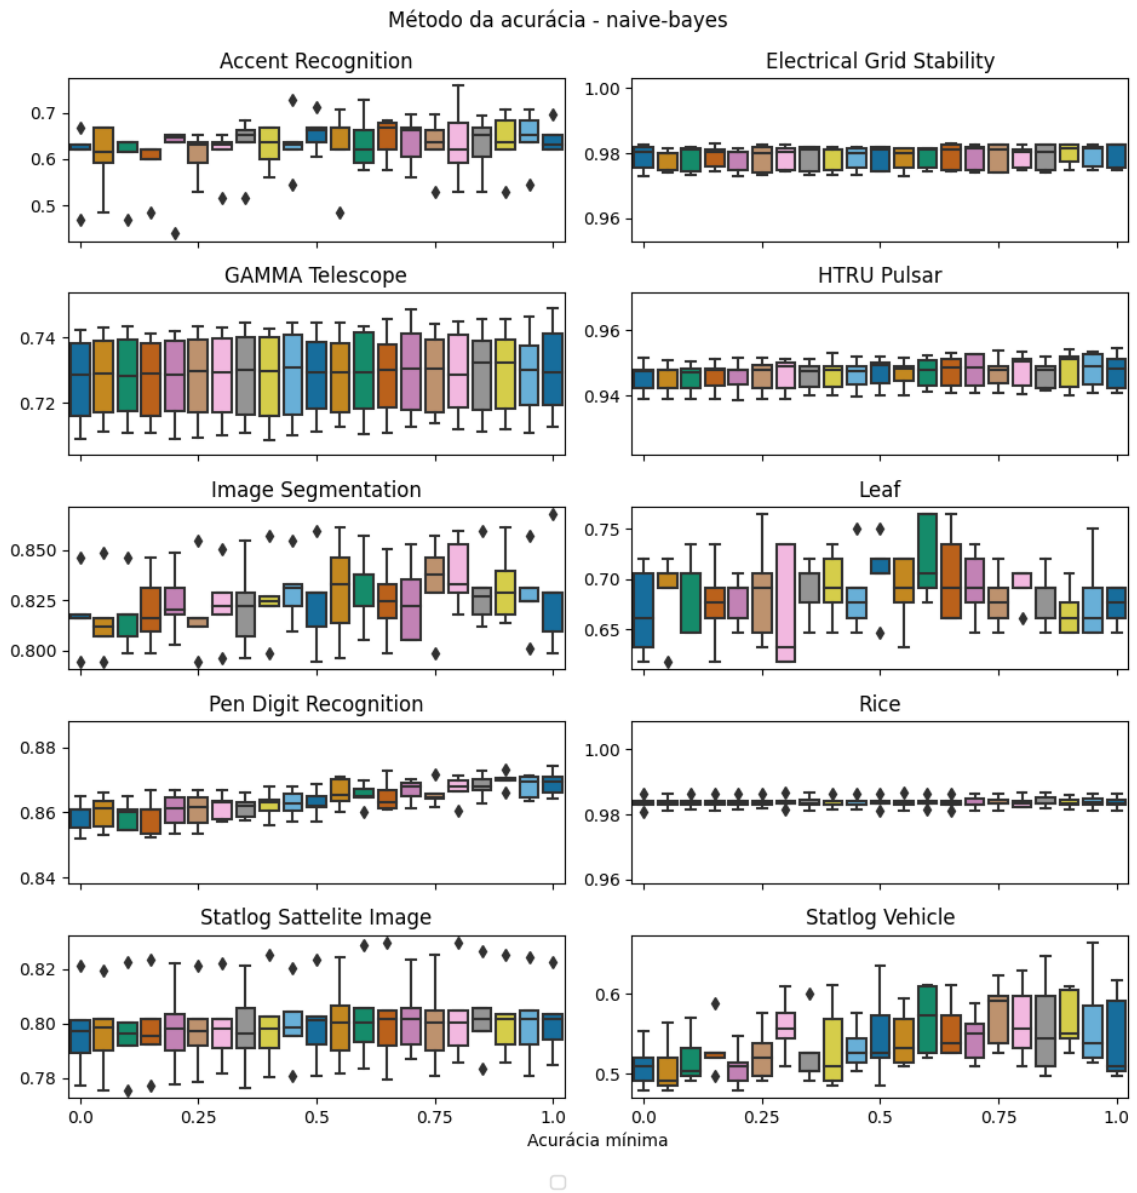


Figura A.3: Resultados do método de acurácia com classificador-base Naïve-Bayes

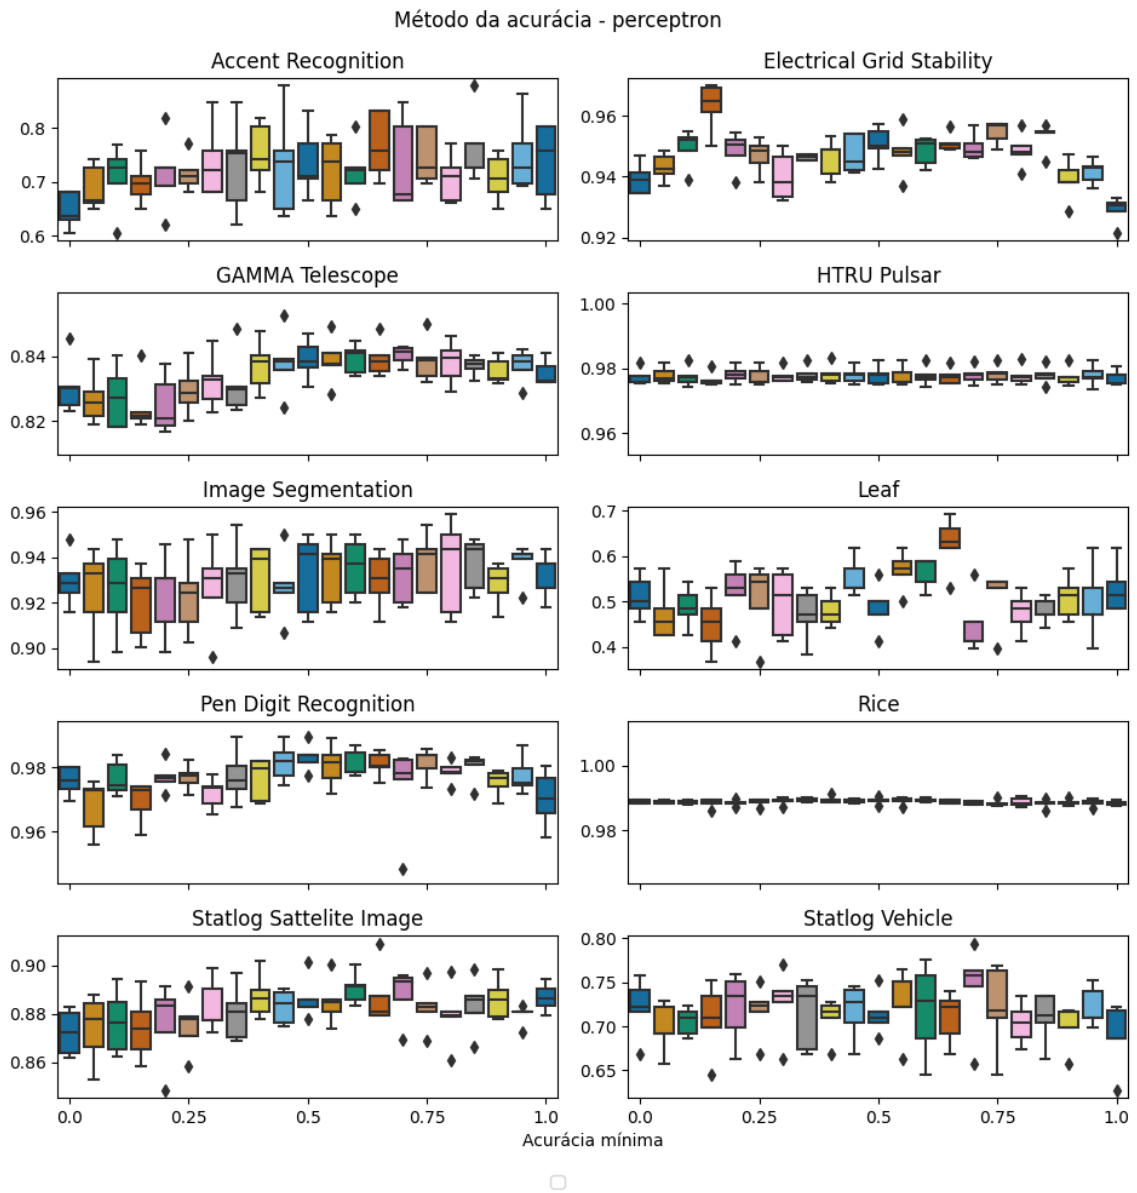


Figura A.4: Resultados do método de acurácia com classificador-base perceptron




Figura A.5: Resultados do método de similaridade com classificador-base kNN




Figura A.6: Resultados do método de similaridade com classificador-base Naïve-Bayes

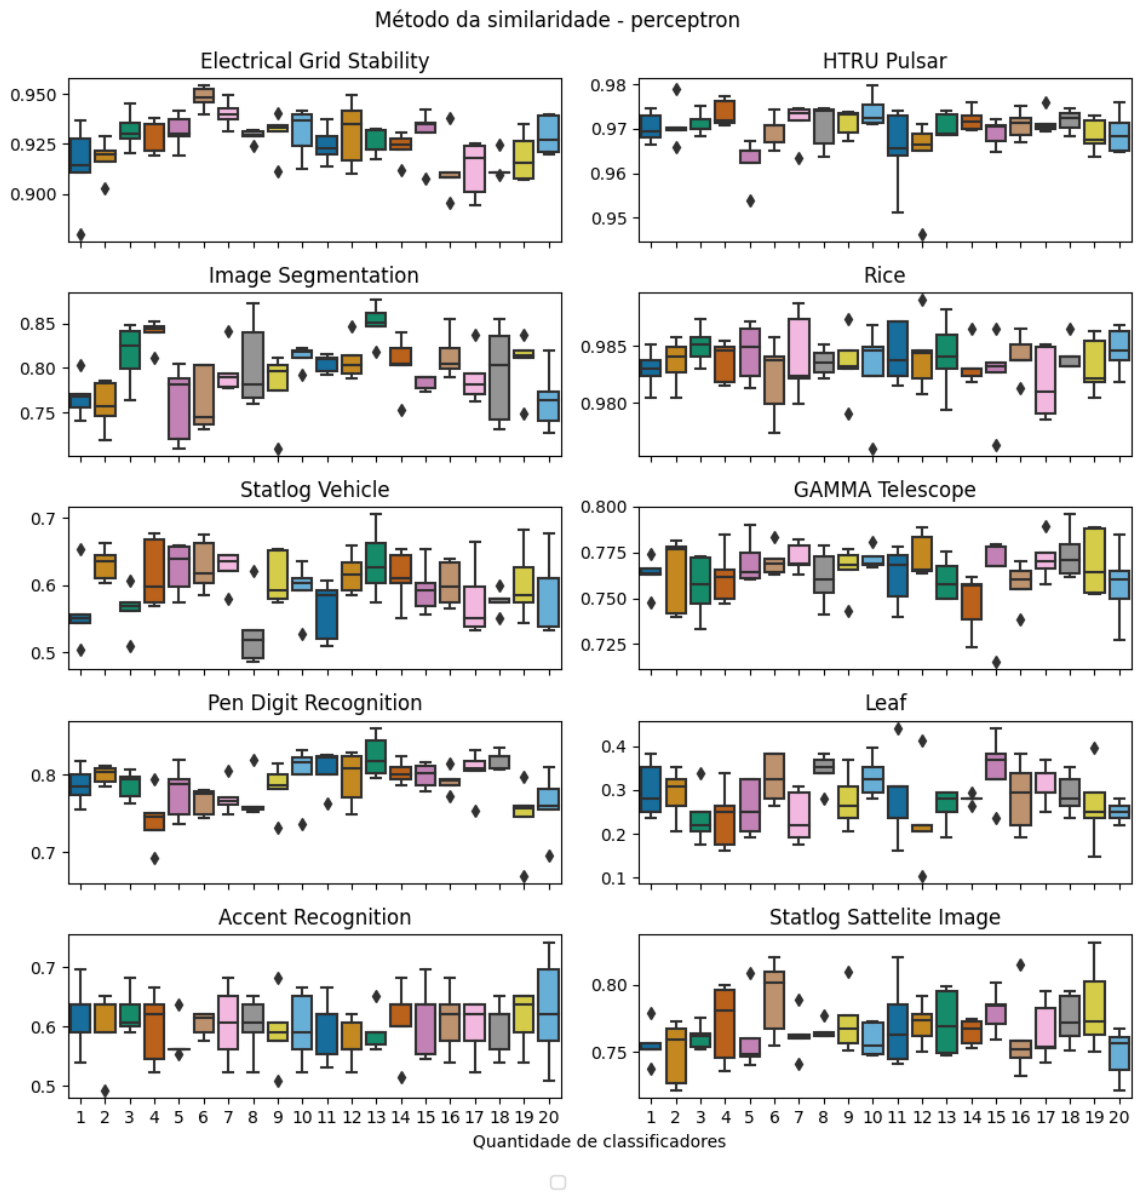


Figura A.7: Resultados do método de similaridade com classificador-base perceptron